

**なぜ Linux は適切な文字を選べない
のか？**

適切に選べないとは？

適切に選べないとは？

メジャーな問題は漢字フォントの選択ミス

日本語として記述された文字が繁体字などで表示される問題。

適切に選べないとは？

メジャーな問題は漢字フォントの選択ミス

日本語として記述された文字が繁体字などで表示される問題。




半分
適切

- 半の字のゝの角度が違う
- 適の部首が二点しんになっている
- etc...

適切に選べないとは？

メジャーな問題は漢字フォントの選択ミス

日本語として記述された文字が繁体字などで表示される問題。



- 半の字のゝの角度が違う
- 適の部首が二点しんになっている
- etc...

実際のところ Linux じゃなくても起こりうる。特に web とか

そもそも文字とは? フォントとは?

そもそも文字とは? フォントとは?

¹ほんとは字形と字体とか細かい話あるけど一旦無視する

そもそも文字とは？ フォントとは？

- script, writing system
- 言語を書き記すための記号
- [A]とか[あ]とか
- 文字は意味と表示を持つ

¹ほんとは字形と字体とか細かい話あるけど一旦無視する

そもそも文字とは？ フォントとは？

- script, writing system
- 言語を書き記すための記号
- [A]とか[あ]とか
- 文字は意味と表示を持つ

一般的なコンピューター環境では

- 意味を文字コードで
- 表示を字体(グリフ, フォント)

で表現する¹

¹ほんとには字形と字体とか細かい話あるけど一旦無視する

文字コードとは

文字コードとは

- コンピュータ上で文字を識別するための規則、ID
- いくつかの種類がある. ASCII, ISO/IEC 8859, Unicode など¹

¹2024 年時点では web の 98% が UTF-8 らしい

文字コードとは

- コンピュータ上で文字を**識別する**ための規則、ID
- いくつかの種類がある. ASCII, ISO/IEC 8859, Unicode など¹

code(dec)	char
00	null
...	
65	A
...	
97	a
127	DEL

¹2024 年時点では web の 98% が UTF-8 らしい

文字コードとは

- コンピュータ上で文字を**識別する**ための規則、ID
- いくつかの種類がある. ASCII, ISO/IEC 8859, Unicode など¹

code(dec)	char
00	null
...	
65	A
...	
97	a
127	DEL

- 各コードポイントに対応する文字がある
- 基本的にはこれを記述したり読み出したりする

¹2024 年時点では web の 98% が UTF-8 らしい

同じ文字？

同じ文字?

消

同じ文字？

消

消

同じ文字？

消

U+6D88

消

同じ文字？

消

U+6D88

- どちらも同じコードポイント

消

同じ文字?

消

消

U+6D88

- どちらも同じコードポイント
- 上は Meiryo フォント
- 下は Anthropic Sans Or System

同じ文字?

消

消

U+6D88

- どちらも同じコードポイント
- 上は Meiryo フォント
- 下は Anthropic Sans Or System
- これらはグリフが違うだけで同じ文字として Unicode では登録されている

同じ文字?

消

消

U+6D88

- どちらも同じコードポイント
- 上は Meiryo フォント
- 下は Anthropic Sans Or System
- これらはグリフが違っただけで同じ文字として Unicode では登録されている

統合漢字

CJK 統合漢字

CJK 統合漢字

ISO/IEC 10646（略称：UCS[1]）および Unicode（）にて採用されている符号化用漢字集合およびその符号表

CJK 統合漢字

ISO/IEC 10646（略称：UCS[1]）および Unicode（）にて採用されている符号化用漢字集合およびその符号表

Unicode の `U+4E00..U+9FFF` の範囲。意味的に同一であればグリフが異なる漢字も同一にしましょうという話。

CJK 統合漢字

ISO/IEC 10646（略称：UCS[1]）および Unicode（）にて採用されている符号化用漢字集合およびその符号表

Unicode の `U+4E00..U+9FFF` の範囲。意味的に同一であればグリフが異なる漢字も同一にしましょうという話。

統合の条件としては

CJK 統合漢字

ISO/IEC 10646（略称：UCS[1]）および Unicode（）にて採用されている符号化用漢字集合およびその符号表

Unicode の `U+4E00..U+9FFF` の範囲。意味的に同一であればグリフが異なる漢字も同一にしましょうという話。

統合の条件としては

- 意味が同一で

CJK 統合漢字

ISO/IEC 10646（略称：UCS[1]）および Unicode（）にて採用されている符号化用漢字集合およびその符号表

Unicode の `U+4E00..U+9FFF` の範囲。意味的に同一であればグリフが異なる漢字も同一にしましょうという話。

統合の条件としては

- 意味が同一で
- 抽象的構造が同一で

CJK 統合漢字

ISO/IEC 10646（略称：UCS[1]）および Unicode（）にて採用されている符号化用漢字集合およびその符号表

Unicode の `U+4E00..U+9FFF` の範囲。意味的に同一であればグリフが異なる漢字も同一にしましょうという話。

統合の条件としては

- 意味が同一で
- 抽象的構造が同一で
- 具体的な字形が異なる

CJK 統合漢字

ISO/IEC 10646（略称：UCS[1]）および Unicode（）にて採用されている符号化用漢字集合およびその符号表

Unicode の `U+4E00..U+9FFF` の範囲。意味的に同一であればグリフが異なる漢字も同一にしましょうという話。

統合の条件としては

- 意味が同一で
- 抽象的構造が同一で
- 具体的な字形が異なる

まあ、色々批判はあったりする。

統合漢字によって CJK の漢字を文字コードレベルで区別できない

統合漢字によって CJK の漢字を文字コードレベルで区別できない

CJK 間でグリフの異なる統合漢字(「直」, 「半」, etc...)を文字コードレベルで区別ができない

統合漢字によって CJK の漢字を文字コードレベルで区別できない

CJK 間でグリフの異なる統合漢字(「直」, 「半」, etc...)を文字コードレベルで区別ができない

⇒ どの文字が表示されるかはフォントの優先度に依存する

統合漢字によって CJK の漢字を文字コードレベルで区別できない

CJK 間でグリフの異なる統合漢字(「直」, 「半」, etc...)を文字コードレベルで区別ができない

⇒ どの文字が表示されるかはフォントの優先度に依存する

こういう資料を作成する際にとても困る

統合漢字によって CJK の漢字を文字コードレベルで区別できない

CJK 間でグリフの異なる統合漢字(「直」, 「半」, etc...)を文字コードレベルで区別ができない

⇒ どの文字が表示されるかはフォントの優先度に依存する

こういう資料を作成する際にとても困る

文字ごとにフォントを当てるとか正気か?

統合漢字によって CJK の漢字を文字コードレベルで区別できない

CJK 間でグリフの異なる統合漢字(「直」, 「半」, etc...)を文字コードレベルで区別ができない

⇒ どの文字が表示されるかはフォントの優先度に依存する

こういう資料を作成する際に**とても**困る

文字ごとにフォントを当てるとか正気か?

最も**困る**領域が Web

どこまでが同じ文字？

どこまでが同じ文字？

(あくまで私見として)

使われる地域が違えば同一の意味を持っていた文字も別の意味を持つ。

↳ 意味が異なるなら、別の字では？

例えば、「湯」は日本語では「お湯」という意味だが、中国語では「スープ」。「愛人」は日本では不倫だが、中国では配偶者や恋人を表す。

フォントが選択されるまで(Web の場合)

フォントが選択されるまで(Web の場合)

フォントが選択されるまで(Web の場合)

Web ページ(CSS)

font-family リスト + lang 属性



Blink スタイル解決

総称名をユーザー設定に置換



文字ごとのマッチング

グリフ有無をフォント毎に確認



システムフォールバック

文字 + lang で OS に問合せ



fontconfig(Linux)

conf.d の規則で候補を並替え

フォントが選択されるまで(Web の場合)

Web ページ(CSS)
font-family リスト + lang 属性



Blink スタイル解決
総称名をユーザー設定に置換



文字ごとのマッチング
グリフ有無をフォント毎に確認



システムフォールバック
文字 + lang で OS に問合せ



fontconfig(Linux)
conf.d の規則で候補を並替え

このような手順でサイトの要求した
フォントは解決される

この間で日本語のフォントが当たらな
いとズレてしまう

Blink はブラウザのエンジン

Case 1. Web サイト側でフォントが完結している

Case 1. Web サイト側でフォントが完結している

Case 1. Web サイト側でフォントが完結している

サイト側でフォントが配信されていて、そこに JP フォントが無い

⇒ フォント解決が Web で完結してしまうため、
基本的にユーザー側でその設定を覆すことはできない

Case 1. Web サイト側でフォントが完結している

サイト側でフォントが配信されていて、そこに JP フォントが無い

⇒ フォント解決が Web で完結してしまうため、
基本的にユーザー側でその設定を覆すことはできない

CSS を注入したり、ブラウザの起動フラグで Web フォントを無効化

Case 1. Web サイト側でフォントが完結している

サイト側でフォントが配信されていて、そこに JP フォントが無い

⇒ フォント解決が Web で完結してしまうため、
基本的にユーザー側でその設定を覆すことはできない

CSS を注入したり、ブラウザの起動フラグで Web フォントを無効化

⇒ 正常なサイトへ影響が出てしまう

Case 2. ローカルへフォールバックされる

Case 2. ローカルフォールバックされる

Web サイトが OS 側の実体フォントを使う場合

`font-family: "Noto Sans JP", ...` のような名前だけの指定、
フォント解決が OS になるため、ユーザーが手を出することができる
Linux では...

`fontconfig` という設定があり、

Case 3. Web サイト側でフォントが完結している

適切にフォントが解決されるとは限らない

適切にフォントが解決されるとは限らない

そもそも Web の時点でフォントが固定される
てしまうと

フォントってなんだよ!

結局フォントってどうするべき？

結局フォントってどうするべき？

- 個人的には Web サイトはその表記した言語のフォントをちゃんと使うべき
- しかし任意の内容を多言語対応することもある
 - SNS とかブログサービスとか
- その場合、静的に CJK の優先度をつけることは難しい
 - 言語推定などによってフォント優先度を動的にする？
 - クライアント側の言語設定に引っ張る？
 - ・ 非本質的な解決ですが楽

{}.com はどうしてる？

{}.com はどうしてる?


x.com

> 今思えば微笑ましい話ですが、その日その時の感情に嘘はないのです。

わかるというか、救いというか
あったかい

かおることゃ @cordx56 · Jun 12


死ねないことに気づいたら | cordx56
sizu.me/cordx56/posts/...



Noto Sans CJK JP になっている

⇒ Twitter はツイートごとに `lang` 属性をつけている
各言語ごとにちゃんとしたフォントが使われる

claude.ai



なぜか Noto Sans CJK KR になっている

⇒ Claude はこのあたりが雑でシステムフォールバック
に落ち、そのあとに私の Linux の設定も雑なので KR に
転んだ
という説もある

I HATE “中華フォント”

I HATE “中華フォント”

私個人としてはあまりこの表記は好きじゃない。
中国語の方が優先されている設定のことが多いせいで、間違いとして繁体字や簡体字などが表示されるだけで別にそれ固有の問題ではない。

ほんとに繁体字で表示される場所に日本の新字体が出ればそれは同型の問題なので、あまり固有名として「中華フォント」という表現は好きじゃない。

— 「確率的存在文字」 — Compute on Snails

お気持ち表明でした
良ければどうぞ →



<https://blog.uliboooo.dev/probabilistic-existence-characters>