

**なぜ Linux は適切な文字を選べない
のか？**

適切に選べないとは？

適切に選べないとは？

メジャーな問題は漢字フォントの選択ミス

日本語として記述された文字が繁体字などで表示される問題。

適切に選べないとは？

メジャーな問題は漢字フォントの選択ミス

日本語として記述された文字が繁体字などで表示される問題。




半分
適切

- 半の字の丶の角度が違う
- 適の部首が二点しんになっている
- etc...

適切に選べないとは？

メジャーな問題は漢字フォントの選択ミス

日本語として記述された文字が繁体字などで表示される問題。



- 半の字の丶の角度が違う
- 適の部首が二点しんになっている
- etc...

実際のところ Linux じゃなくても起こりうる。特に web とか

そもそも文字とは？ フォントとは？

そもそも文字とは? フォントとは?

¹ほんとは字形と字体とか細かい話あるけど一旦無視する

そもそも文字とは？ フォントとは？

- script, writing system
- 言語を書き記すための記号
- [A]とか[あ]とか
- 文字は意味と表示を持つ

¹ほんとは字形と字体とか細かい話あるけど一旦無視する

そもそも文字とは? フォントとは?

- script, writing system
- 言語を書き記すための記号
- [A]とか[あ]とか
- 文字は意味と表示を持つ

一般的なコンピューター環境では

- 意味を文字コードで
- 表示を字体(グリフ, フォント)

で表現する¹

¹ほんととは字形と字体とか細かい話あるけど一旦無視する

文字コードとは

文字コードとは

- コンピュータ上で文字を識別するための規則、ID
- いくつかの種類がある. ASCII, ISO/IEC 8859, Unicode など¹

¹2024 年時点では web の 98% が UTF-8 らしい

文字コードとは

- コンピュータ上で文字を**識別する**ための規則、ID
- いくつかの種類がある. ASCII, ISO/IEC 8859, Unicode など¹

code(dec)	char
00	null
...	
65	A
...	
97	a
127	DEL

¹2024 年時点では web の 98% が UTF-8 らしい

文字コードとは

- コンピュータ上で文字を**識別する**ための規則、ID
- いくつかの種類がある. ASCII, ISO/IEC 8859, Unicode など¹

code(dec)	char
00	null
...	
65	A
...	
97	a
127	DEL

- 各コードポイントに対応する文字がある
- 基本的にはこれを記述したり読み出したりする

¹2024 年時点では web の 98% が UTF-8 らしい

同じ文字？

同じ文字?

消

同じ文字？

消

消

同じ文字？

消

U+6D88

消

同じ文字？

消

U+6D88

- どちらも同じコードポイント

消

同じ文字?

消

消

U+6D88

- どちらも同じコードポイント
- 上は Meiryo フォント
- 下は Anthropic Sans Or System

同じ文字?

消

消

U+6D88

- どちらも同じコードポイント
- 上は Meiryo フォント
- 下は Anthropic Sans Or System
- これらはグリフが違うだけで同じ文字として Unicode では登録されている

同じ文字？

消

消

U+6D88

- どちらも同じコードポイント
- 上は Meiryo フォント
- 下は Anthropic Sans Or System
- これらはグリフが違っただけで同じ文字として Unicode では登録されている

統合漢字

CJK 統合漢字

CJK 統合漢字

ISO/IEC 10646（略称：UCS[1]）および Unicode（）にて採用されている符号化用漢字集合およびその符号表

CJK 統合漢字

ISO/IEC 10646（略称：UCS[1]）および Unicode（）にて採用されている符号化用漢字集合およびその符号表

Unicode の `U+4E00..U+9FFF` の範囲。意味的に同一であればグリフが異なる漢字も同一にしましょうという話。

CJK 統合漢字

ISO/IEC 10646（略称：UCS[1]）および Unicode（）にて採用されている符号化用漢字集合およびその符号表

Unicode の `U+4E00..U+9FFF` の範囲。意味的に同一であればグリフが異なる漢字も同一にしましょうという話。

統合の条件としては

CJK 統合漢字

ISO/IEC 10646（略称：UCS[1]）および Unicode（）にて採用されている符号化用漢字集合およびその符号表

Unicode の `U+4E00..U+9FFF` の範囲。意味的に同一であればグリフが異なる漢字も同一にしましょうという話。

統合の条件としては

- 意味が同一で

CJK 統合漢字

ISO/IEC 10646（略称：UCS[1]）および Unicode（）にて採用されている符号化用漢字集合およびその符号表

Unicode の `U+4E00..U+9FFF` の範囲。意味的に同一であればグリフが異なる漢字も同一にしましょうという話。

統合の条件としては

- 意味が同一で
- 抽象的構造が同一で

CJK 統合漢字

ISO/IEC 10646（略称：UCS[1]）および Unicode（）にて採用されている符号化用漢字集合およびその符号表

Unicode の `U+4E00..U+9FFF` の範囲。意味的に同一であればグリフが異なる漢字も同一にしましょうという話。

統合の条件としては

- 意味が同一で
- 抽象的構造が同一で
- 具体的な字形が異なる

CJK 統合漢字

ISO/IEC 10646（略称：UCS[1]）および Unicode（）にて採用されている符号化用漢字集合およびその符号表

Unicode の `U+4E00..U+9FFF` の範囲。意味的に同一であればグリフが異なる漢字も同一にしましょうという話。

統合の条件としては

- 意味が同一で
- 抽象的構造が同一で
- 具体的な字形が異なる

まあ、色々批判はあったりする。

どこまでが同じ文字？

どこまでが同じ文字？

(あくまで私見として)

使われる地域が違えば同一の意味を持っていた文字も別の意味を持つ。

↳ 意味が異なるなら最早、別の字では？

例えば、「湯」は日本語では「お湯」という意味だが、中国語では「スープ」。「愛人」は日本では不倫だが、中国では配偶者や恋人を表す。

フォントが選択されるまで

フォントが選択されるまで

